



Projet : Analysez les ventes d'une librairie avec R ou Python - Jordan Canonne

Problématique / Contexte

Comment optimiser les performances de vente en ligne de l'entreprise Lapage en comprenant les comportements des clients et en identifiant les leviers stratégiques à mettre en œuvre?

Sources des données

Origine des données	Données extraites	Documents associés
• Lapage : L'entreprise Lapage était originellement une librairie physique avec plusieurs points de vente. Mais devant le succès de certains de ses produits et l'engouement de ses clients, elle a décidé depuis 2 ans d'ouvrir un site de vente en ligne.	• Informations sur les clients (ID, genre, âge) • Informations sur les produits (ID, prix, catégorie) • Historique des ventes (ID produit, ID client, date, ID Session).	• clients.csv • produits.csv • ventes.csv

Plan d'action

Partie I : Analyse des indicateurs de vente

- Chiffre d'affaires et nombre de transactions
- Distribution des prix des produits
- Mesure de tendance (via la Moyenne Mobile)
- Zoom sur les références
- Informations sur les profils des clients
- Répartition du chiffre d'affaires entre clients

Partie 2 : Analyse des comportements clients

- **Observation et analyse (tests statistiques) des corrélations entre :**
 - le genre des clients et les catégories de livres achetés.
 - l'âge des clients et le montant total des achats.
 - l'âge des clients et la fréquence d'achat.
 - l'âge des clients et le panier moyen.
 - l'âge des clients et la catégorie des livres achetés.

Partie 3 : Conclusion

Partie I

Analyse des indicateurs de vente

Chiffre d'affaires et nombre de transactions


12 027 663 € de CA total du 03/01/2021 au 28/02/2023

4 419 731 € de CA généré par la catégorie 0

4 827 657 € de CA généré par la catégorie 1

2 780 275 € de CA généré par la catégorie 2

Répartition du chiffre d'affaires entre les catégories 0,1 et 2




687 534 transactions au total effectuées durant cette période

415 459 transactions pour la catégorie 0


235 592 transactions pour la catégorie 1

36 483 transactions pour la catégorie 2

Répartition des effectifs de vente entre les catégories 0, 1 et 2




Distribution du prix des produits



Indicateurs	Prix (valeurs arrondies)
Nombre de produits	3265
Prix moyen	21.8 €
Ecart type	29.6 €
Prix min	0.62 €
25% (Q1)	6.99 €
50% (Q2) (Prix médian)	13 €
75% (Q3)	22.99 €
Prix max	300 €
Prix le plus fréquent	5 €
IQR	10.9 €

Mesure de tendance (via la Moyenne Mobile)

Courbe des prix par jour et moyenne mobile



Analyse des variabilités marquantes :

Dates clés (périodes 1 et 2) :

- 28/08/2021 au 27/10/2021
- 26/12/2021 au 26/03/2022

Analyses faites sur ces deux périodes :

- Top 10 produits par CA
- Catégories préférées
- CA par genre

Observations (via le notebook) :

- Aucune cause claire pour les variations de CA entre 28/08 et 27/10
- Top clients et produit phare et CA genre sans effet significatif

Actions:

- Explorer d'autres hypothèses
- Revoir la collecte de données

Moyenne du chiffre d'affaires généré par jour : **16 476.25 €**

Zoom sur les références

Top 10 des produits ayant généré le plus de CA

id_prod	Chiffre d'affaires
2_159	94893.5
2_135	69334.95
2_112	65407.76
2_102	60736.78
2_209	56971.86
1_395	56617.47
1_369	56136.6
2_110	53846.25
1_383	53834.43
1_414	53522.18

Top 10 des produits les plus vendus

id_prod	Nombre de ventes
1_369	2340
1_417	2269
1_414	2246
1_498	2202
1_425	2163
1_403	2040
1_413	2036
1_412	2014
1_406	2003
1_407	2001

Top 10 des produits ayant généré le moins de CA

id_prod	Chiffre d'affaires
0_1539	0.99
0_1284	1.38
0_1653	1.98
0_541	1.99
0_1601	1.99
0_807	1.99
0_1728	2.27
0_1498	2.48
0_898	2.54
0_1840	2.56

25 % des produits les moins vendus



	Nombre de ventes par produit
count	843
mean	9.079478
std	4.380598
min	1
25%	5
50%	9
75%	13
max	17

Moyenne Générale des Ventes :

Sur l'ensemble des 3 265 produits, la moyenne des ventes par produit s'établit à 210.



Segment des 25% Moins Vendus :

Parmi les 3 265 produits, 843 (soit 25%) se distinguent par des ventes particulièrement basses, allant de 1 à 17 ventes par produit, ce qui contraste nettement avec la moyenne globale de 210 ventes.




Observation du cas concernant les 25 % produits les moins vendus

Informations sur les profils des clients



Analyse équilibrée : répartition homogène entre hommes et femmes


Informations sur les profils des clients



Analyse équilibrée : répartition homogène entre hommes et femmes

Informations sur les profils des clients

Répartition par catégorie et tranche d'âge (%)



Catégorie 0 :

Forte dominance des clients âgés de 41-50 ans

Catégorie 1 :

Distribution plus équilibrée, avec une légère prédominance des 41-50 et 51-60 ans



Catégorie 2 :

Jeunesse prédominante, plus de 70% des participants ont entre 20-30 ans

Observation clé :

Concentration marquée des clients de 61 à 95 ans dans toutes les catégories, indiquant une représentation inférieure des âges avancés par rapport aux autres tranches



Informations sur les profils des clients



Profil client majoritairement jeune ; répartition équilibrée entre 20-30 et 51-60 ans, diminution progressive chez les plus de 60 ans.

Point important : pic significatif chez les 20 ans.


Informations sur les profils des clients



Chiffre d'affaires dominant chez les tranches d'âges allant de 20-30 ans à 41-50 ans, puis décroissance avec l'âge.

Pic significatif du chiffre d'affaires chez les groupes de clients de 20, 25 et 45 ans


Top 10 : Principaux Pics de Chiffre d'Affaires par Âge - Focus sur 20, 25 et 45 Ans



Les groupes d'âge montrent des comportements d'achat similaires, avec un volume de ventes par produit variant de 89 à 170 unités à des prix comparables par groupe d'âge, particulièrement parmi les 20-25 ans.

Notons des exceptions pour certains produits vendus en quantités moindres (environ 30 unités) mais à des prix plus élevés.

Répartition du chiffre d'affaires entre clients




Indice de Gini : 0.39

Un indice de Gini de 0.39 signale une inégalité modérée dans la distribution du chiffre d'affaires parmi les clients

Répartition du chiffre d'affaires entre clients

Répartition du Chiffre d'Affaires: Top 4 des Clients vs. Reste des Clients




client_id	Prix
c_1609	326 039.89
c_4958	290 227.03
c_6714	153 918.60
c_3454	114 110.57
c_1570	5 285.82
c_3263	5 276.87
c_2140	5 260.18
c_2899	5 214.05
c_7319	5 155.77
c_7959	5 135.75

Observation :

Baisse drastique de 95.4% du chiffre d'affaires entre le 4e et 5e plus grand client, soulignant une concentration extrême des revenus chez les clients principaux. (Basé sur le calcul de pourcentage différentiel)

Répartition du chiffre d'affaires et des effectifs entre clients



client_id	nb_commande_quotidienne_au_total
c_1609	730
c_3454	730
c_6714	730
c_4958	728
c_2140	316
c_3263	307
c_1570	305
c_1637	305
c_1876	299
c_669	294


Nombre moyen de jours de visite par client (sur ces deux années) : 68

Clients avec un nombre de commandes cumulées supérieurs à la moyenne : 3 109 sur 8 600 clients

Partie II

Analyse des comportements clients

Lien entre le genre des clients et les catégories de livres achetés



Test choisis : test du Chi2


Résultat :

P-valeur < 0.01

On rejette H0

Il existe un lien statistiquement significatif entre le genre des clients et les catégories de livres qu'ils achètent.

Lien entre l'âge des clients et le montant total des achats (I)



1^{er} test choisis :

Pearson :

Résultat du coefficient de corrélation :


-0.77 (avec outlier)

-0.83 (sans outlier)

Une valeur proche de -1 indique une corrélation négative.

Il existe un lien significatif entre l'âge des clients et la fréquence d'achat, avec une tendance à une diminution de la fréquence d'achat à mesure que l'âge augmente

Lien entre l'âge des clients et le montant total des achats (2)



2^{ème} test choisis :

Régression linéaire :


Résultat :

P-valeur < 0.05

On rejette H0

Il existe un lien significatif entre l'âge des clients et la fréquence d'achat, avec une tendance à une diminution de la fréquence d'achat à mesure que l'âge augmente

Lien entre l'âge des clients et le montant total des achats (3)




3^{ème} test choisis : Test de Welch entre sous-groupes :

But : comparer les 20-32 ans + 33-53 ans par rapport aux 54-95 ans car nous avons vu que le chiffre d'affaires était dominant chez les tranches d'âges allant de 20-30 ans à 41-50 ans puis décroissait avec l'âge.

Décomposition en trois groupes de tranches d'âges : 20 à 32 ans / 33 à 52 ans / 53 à 95 ans. (choix des tranches établie grâce aux statistiques descriptives faites en amont + ajout du graphique concernant le panier moyen par session qui nous montre des comportements d'achats différents selon ces sous-ensembles et permet d'appuyer cette hypothèse de sous-groupe même si nous n'avons pas fait de test de corrélation entre le montant total et le panier moyen, ce sont juste des indicateurs).


Résultat : comparaison entre les :

- 20-32 ans et 33-52 ans : P-valeur > 0.05 : On rejette H1
- 20-32 ans et 53-95 ans : P-valeur < 0.05 : On rejette H0
- 33-52 ans et 53-95 ans : P-valeur < 0.05 : On rejette H0



Il existe un lien significatif entre l'âge des clients et la fréquence d'achat, avec une tendance à une diminution de la fréquence d'achat à mesure que l'âge augmente

Lien entre l'âge des clients et la fréquence d'achat



Test choisis : Test de Spearman


Résultat :

P-valeur < 0.05

On rejette H0

L'analyse statistique suggère qu'il existe un lien statistiquement significatif entre l'âge des clients et leur fréquence d'achat

Lien entre l'âge des clients et le panier moyen



Test choisis : Test de Spearman


Résultat :

P-valeur < 0.05

On rejette H0

L'analyse statistique suggère qu'il existe un lien statistiquement significatif entre l'âge des clients et la taille de leur panier moyen, avec une corrélation négative indiquant que plus l'âge augmente, moins les clients achètent d'articles

Lien entre l'âge des clients et les catégories de livres achetés



Test choisis : Test de Kruskal-Wallis

Résultat :

P-valeur < 0.05

On rejette H0

Il existe une association significative entre l'âge des clients et les catégories de produits qu'ils achètent dans une boutique de livres en ligne

Partie III

Conclusion

Conclusion


Tranche d'Âge	Chiffre d'Affaires	Nombre de Clients Uniques	Pourcentage de Clients (%)	Pourcentage du Total du CA (%)
<u>20-32</u>	3 334 899	2 267	26.4	27.7
<u>33-52</u>	5 400 997	3 225	37.5	<u>44.9</u>
53-95	3 291 767	3 108	36.1	27.4

- **Priorité aux tranches d'âge 20-32 et 33-52 ans pour des stratégies à court terme, grâce à une meilleure compréhension de leur comportement d'achat (et porter une attention particulière aux 33-52 ans qui génèrent près de la moitié du CA global, soit : 44.9%)**
- **Stratégies à long terme nécessaires pour la tranche d'âge **53-95** ans, en raison d'une plus grande variabilité générationnelle et d'un besoin d'informations supplémentaires**

Recommandations

- **Segmentation ciblée** : adaptation des stratégies marketing à l'âge des clients, avec une attention particulière aux groupes plus âgés pour augmenter la fréquence d'achat.
- **Personnalisation par genre** : recommandations de catégories de livres basées sur le genre pour affiner le ciblage et améliorer l'engagement.
- **Gestion des paniers** : initiatives pour augmenter la taille des paniers chez les clients plus âgés, qui tendent à acheter moins par session.
- **Adaptation de l'offre** : ajustement de l'inventaire en fonction des préférences de catégories de livres liées à l'âge.
- **Expérience utilisateur optimisée** : amélioration de l'accessibilité du site pour augmenter l'engagement des segments d'âge supérieurs.
- **Analyse continue** : suivi régulier des comportements pour ajuster dynamiquement les stratégies.
- **Communication sur mesure** : campagnes de marketing personnalisées alignées sur les intérêts littéraires et démographiques des clients.
- **Programmes de fidélisation** : développement de programmes pour accroître la fidélité et encourager des achats répétés, avec des offres spéciales pour les tranches d'âge clés.


Annexe




Les jeunes âgés de 20-32 ans sont grandement responsable de la consommation de produits à haute valeur

Annexe

Répartition entre les transactions standards et à haute valeur



Comparaison du CA : Clients (Outliers) vs Clients (Non-Outliers)



Les jeunes (20-32 ans) achètent plus chère et en moins grande quantité, ils sont pratiquement entièrement responsables de la consommation de produits à haute valeur